БОЛЬШИЕ ЯЗЫКОВЫЕ МОДЕЛИ (НА ОСНОВЕ TRANSFORMERS)

ТРИ ПРИКЛАДНЫХ КЕЙСА - СЛОЖНЫЙ УРОВЕНЬ

ОБЩИЕ УСЛОВИЯ

Максимальная оценка за каждый кейс - 100 баллов.

Команда - от 1 до 5 человек. Функциональные роли: лидер, программист, аналитик данных, исследователь и архитектор сети. При меньшем составе роли совмещаются; в отчете фиксируется персональный вклад.

большая языковая модель (LLM) является обязательной частью системы. Нельзя ограничиться только классификатором, регрессором или поиском.

трансформер (Transformer)s применяются именно для экспериментального улучшения базового решения. Сам факт использования трансформер (Transformer) не считается улучшением: прирост должен быть измерен на неизменной тестовой выборке (тестовая выборка (test set)).

Обязательная исследовательская цепочка: базовое решение (baseline) -> трансформер (Transformer) -> трансформер (Transformer) + большая языковая модель (LLM) -> улучшенная трансформер (Transformer) + большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))-система -> абляционное исследование (абляционное исследование (ablation) study) -> статистическая проверка.

Все эксперименты должны быть воспроизводимыми: фиксированный начальное значение генератора случайных чисел (seed), описанные версии моделей и библиотек, неизменный тестовая выборка (test set), сохраненные предсказания и ответы большая языковая модель (LLM).

Разрешены Hugging Face трансформер (Transformer)s, Sentence трансформер (Transformer)s, параметрически эффективное дообучение (PEFT)/низкоранговая адаптация (LoRA), PyTorch/TensorFlow, scikit-learn, библиотеки векторного поиска и локальные/облачные большая языковая модель (LLM) при документировании модели и параметров.

КЕЙС 1. ПРОМЫШЛЕННОСТЬ: большая языковая модель (LLM)-СИСТЕМА ДИАГНОСТИКИ, ПРОГНОЗА ОТКАЗА И ОБОСНОВАНИЯ ТЕХНИЧЕСКОГО РЕШЕНИЯ

1. Постановка задачи

Промышленному предприятию требуется исследовательский прототип интеллектуальной поддержки технического обслуживания. Система должна объединять числовые параметры оборудования, текстовые журналы операторов и ссылки на технические документы. Базовая модель прогнозирует риск отказа без трансформер (Transformer). трансформер (Transformer) должен улучшить представление временных/текстовых признаков, а большая языковая модель (LLM) - сформировать проверяемое диагностическое заключение, опираясь только на модельный прогноз и предоставленный технический контекст.

2. ДАНО

2.1. Обучающая база. Файл «Кейс_1_сложный_промышленность_15000.csv», 15 000 событий. Поля: оборудование (equipment), operating_hours, temperature_c, vibration_mm_s, pressure_bar, load_ratio, журнал оператора (operator_log), идентификатор руководства (manual_id), тип неисправности (fault_type), тяжесть/критичность (severity), required_route, horizon_days, отказ в течение 30 дней (failure_within_30d).

2.2. Исследуемые системы. A - классический базовое решение (baseline) по числовым признакам; B - трансформер (Transformer)/encoder для текста журнала и/или последовательных признаков; C - объединение признаков/моделей (fusion)-модель числовых и трансформер (Transformer)-признаков; D - C + генерация с дополнением поиском (RAG) по техническим материалам + большая языковая модель (LLM)-объяснение.

2.3. Исследовательские гипотезы. H1: признаки трансформера (трансформер (Transformer) features) повышают качество прогноза относительно классического базовое решение (baseline). H2: объединение числовых и текстовых признаков дает больший прирост, чем любой источник отдельно. H3: генерация с дополнением поиском (RAG) уменьшает долю неподтвержденных утверждений большая языковая модель (LLM). H4: прирост зависит от типа оборудования и редкости класса.

2.4. Выход большая языковая модель (LLM). Структурированное заключение: оборудование; прогноз риска; предполагаемый тип неисправности; ключевые признаки; рекомендуемый маршрут; ссылки идентификатор руководства (manual_id); уровень уверенности; ограничения вывода.

3. ТРЕБУЕТСЯ НАЙТИ (ОПРЕДЕЛИТЬ)

1. Провести разведочный анализ данных (EDA) и исследовать баланс тип неисправности (fault_type), тяжесть/критичность (severity), оборудование (equipment) и отказ в течение 30 дней (failure_within_30d); проверить пропуски, дубликаты и выбросы.

2. Сформировать обучающая/валидационная/тестовая выборки (train/валидация (validation)/test) без утечки; обосновать стратегию разбиения и проверить отсутствие повторов между частями.

3. Реализовать базовое решение (baseline) без трансформер (Transformer): Logistic Regression/Random Forest/Gradient Boosting по числовым признакам.

4. Обучить трансформер-компонент (трансформер (Transformer) component) для журнал оператора (operator_log) либо последовательного представления признаков; архитектор сети обязан обосновать выбор.

5. Построить объединение признаков/моделей (fusion)-модель и сравнить: только числовые признаки (numeric only), только текстовые признаки (text only), трансформер (Transformer) only, объединение признаков/моделей (fusion).

6. Для отказ в течение 30 дней (failure_within_30d) рассчитать площадь под ROC-кривой (ROC-AUC), площадь под кривой точность-полнота (PR-AUC), F1-мера (F1), полнота (recall); для тип неисправности (fault_type) - макроусреднённая F1-мера (F1)-мера (macro-F1-мера (F1)), per-class точность (precision)/полнота (recall) и матрица ошибок (conобъединение признаков/моделей (fusion) matrix).

7. Провести абляционное исследование (абляционное исследование (ablation) study): удалить по очереди журнал оператора (operator_log), числовые сенсоры, трансформер (Transformer)-эмбеддинги и генерация с дополнением поиском (RAG).

8. Проверить статистическую устойчивость улучшения базовое решение (baseline) -> трансформер (Transformer) минимум на 5 повторных запусках/бутстрэп-выборках; дать доверительный интервал.

9. Исследовать не менее 20 ошибок, разделив их по типам: редкий класс, пограничные сенсоры, противоречивый журнал, ошибка маршрутизации.

10. Сформировать технический корпус для генерация с дополнением поиском (RAG) из карточек идентификатор руководства (manual_id) и реализовать информационный поиск (retrieval); измерить полнота в первых k результатах (Recall@k)/средний обратный ранг (MRR) для релевантного документа.

11. Сгенерировать большая языковая модель (LLM)-заключения минимум для 200 объектов тестовой выборки (test) в двух режимах: без генерация с дополнением поиском (RAG) и с генерация с дополнением поиском (RAG).

12. Разработать рубрику ручной оценки большая языковая модель (LLM): фактическая согласованность (factual consistency), соответствие прогнозу модели, опора на источник, отсутствие вымышленных действий.

13. Вручную оценить минимум 100 пар ответов большая языковая модель (LLM) без генерация с дополнением поиском (RAG)/с генерация с дополнением поиском (RAG); посчитать долю неподтвержденных утверждений.

14. Исследовать, коррелирует ли качество классификатора/прогноза с качеством конечного большая языковая модель (LLM)-заключения.

15. Провести анализ по подгруппам оборудования и тяжесть/критичность (severity); установить, где трансформер (Transformer) дает наибольший и наименьший прирост.

16. Сравнить вычислительную стоимость, время обучения и инференса четырех систем.

17. Сформулировать не менее 5 содержательных выводов и отдельно указать случаи, когда усложнение трансформер (Transformer)/большая языковая модель (LLM) не оправдано.

4. Что должно быть в итоговой таблице

Модель	площадь под ROC-кривой (ROC-AUC)	площадь под кривой точность-полнота (PR-AUC)	макроусреднённая F1-мера (F1)-мера (macro-F1-мера (F1))	полнота для высокого риска (Recall high-risk)	большая языковая модель (LLM) верность источнику (faithfulness)	доля галлюцинаций (Hallucination rate)	Latency
Baseline	-	-	-	-	-	-	-
трансформер (Transformer)	-	-	-	-	-	-	-
трансформер (Transformer) + большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))	-	-	-	-	-	-	-

5. Критерии оценивания работы

Критерий	Макс. балл
Организация, роли и воспроизводимость	6
Исследование данных и утечка данных (data leakage)	10
Baseline	8
трансформер (Transformer) и архитектура объединение признаков/моделей (fusion)	18
Эксперименты, абляционное исследование (ablation) и статистика	18
генерация с дополнением поиском (RAG) и большая языковая модель (LLM)-компонент	16
Анализ ошибок и интерпретация	10
Отчет	7
Защита	7

Максимальный балл: 100.

Разъяснение к оцениванию: оценивается качество исследовательской постановки, корректность сравнения на одном тестовая выборка (test set), доказательность улучшения трансформер-компонент (трансформер (Transformer) component)а, качество интеграции с большая языковая модель (LLM), воспроизводимость и глубина анализа. Высокая метрика сама по себе не компенсирует утечка данных (data leakage), отсутствие базовое решение (baseline), некорректный эксперимент или неподтвержденные выводы.

Итоговый балл	Пояснение
90-100	Исследование выполнено полно; улучшение доказано, абляционное исследование (ablation) и статистическая проверка корректны, большая языковая модель (LLM)-компонент проверяем и обоснован.
80-89	Сильная работа с небольшими недостатками в экспериментальном дизайне или анализе.
70-79	Основная система реализована, но исследовательская часть или доказательство прироста недостаточно глубоки.
60-69	Есть рабочие модели и сравнение, но абляционное исследование (ablation)/statistics/большая языковая модель (LLM) evaluation выполнены частично.
50-59	Решение фрагментарно; трансформер (Transformer)/большая языковая модель (LLM) используются, но улучшение не доказано убедительно.
0-49	Не выполнены ключевые требования, отсутствует корректный базовое решение (baseline)/test comparison или исследовательская работа.

КЕЙС 2. КРУПНАЯ КОМПАНИЯ: ИССЛЕДОВАНИЕ МНОГОЭТАПНОЙ большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))-СИСТЕМЫ С ОБУЧАЕМЫМ RETRIEVAL И RERANKING

1. Постановка задачи

Крупная компания создает корпоративного большая языковая модель (LLM)-ассистента по внутренним регламентам. Необходимо исследовать, при каких условиях поиск на основе трансформера (трансформер (Transformer)-based информационный поиск (retrieval)) и повторное ранжирование (reranking) действительно улучшают конечный ответ большая языковая модель (LLM) по сравнению с лексическим базовое решение (baseline). Работа должна разделять качество поиска и качество генерации и экспериментально установить причинную связь между ними.

2. ДАНО

2.1. Обучающая база. Файл «Кейс_2_сложный_корпоративный_генерация с дополнением поиском (RAG)_15000.csv», 15 000 запрос-документ (query-document) пар. Есть идентификатор эталонного документа (gold_идентификатор документа (document_id)), идентификатор документа-кандидата (candidate_идентификатор документа (document_id)), подразделение (department), тема (topic), релевантность (relevant) и сложный отрицательный пример (hard_negative). В базе присутствуют положительные пары и сложные отрицательные примеры.

2.2. Исследуемые системы. A - BM25/TF-IDF -> большая языковая модель (LLM); B - предварительно обученные плотные векторные представления (pretrained dense embeddings) -> большая языковая модель (LLM); C - обученный двухбашенный кодировщик (bi-encoder) -> большая языковая модель (LLM); D - гибридный поиск (hybrid информационный поиск (retrieval)) + перекрёстный кодировщик (cross-encoder)/большая языковая модель (LLM) повторное ранжирование (reranking) -> большая языковая модель (LLM).

2.3. Исследовательские гипотезы. H1: обучаемый плотный семантический поиск (dense информационный поиск (retrieval)) улучшает полнота в первых k результатах (Recall@k) на семантически перефразированных запросах. H2: обучение на сложных отрицательных примерах (hard-negative training) дает больший прирост, чем случайные negatives. H3: повторное ранжирование (reranking) повышает качество ответа только при достаточном полнота (recall) первого этапа. H4: максимальный оценка качества поиска (информационный поиск (retrieval) score) не гарантирует максимальную верность источнику (faithfulness) большая языковая модель (LLM).

2.4. Ограничение генерации. большая языковая модель (LLM) должен отвечать только по извлечённый контекст (retrieved context), приводить идентификатор документа (document_id) и явно сообщать об отсутствии достаточного основания.

3. ТРЕБУЕТСЯ НАЙТИ (ОПРЕДЕЛИТЬ)

1. Провести разведочный анализ данных (EDA) по подразделение (department), тема (topic), релевантность (relevant), сложный отрицательный пример (hard_negative) и типам запросов.

2. Создать на уровне запросов (query-level) обучающая/валидационная/тестовая выборки (train/валидация (validation)/test), исключив утечку одинаковых запросов и документов.

3. Реализовать BM25/TF-IDF базовое решение (baseline) и измерить полнота в первых 1/3/5/10 результатах (полнота в первых 1/3/5 результатах (Recall@1/3/5)/10), средний обратный ранг (MRR) и нормированная дисконтированная накопленная полезность (nDCG).

4. Реализовать pretrained векторные представления трансформера (трансформер (Transformer) embeddings) без дообучения и сравнить с базовое решение (baseline).

5. Обучить двухбашенный кодировщик (bi-encoder) на положительные/отрицательные пары (positive/negative pairs); отдельно исследовать случайные отрицательные примеры (random negatives) и сложные отрицательные примеры (hard negatives).

6. Реализовать повторное ранжирование (reranking) первые k результатов (top-k) кандидатов перекрёстный кодировщик (cross-encoder) или большая языковая модель (LLM)-модель повторного ранжирования (большая языковая модель (LLM)-модель повторного ранжирования (reranker)).

7. Построить гибридный поиск (hybrid информационный поиск (retrieval)) и обосновать способ объединение признаков/моделей (fusion) sparse+dense.

8. Провести абляционное исследование (абляционное исследование (ablation) study) по размер фрагмента (chunk size), overlap, первые k результатов (top-k), сложные отрицательные примеры (hard negatives), модель повторного ранжирования (reranker) и hybrid объединение признаков/моделей (fusion).

9. Провести минимум 5 повторных экспериментов/бутстрэп и оценить доверительные интервалы для ключевых информационный поиск (retrieval)-метрик.

10. Проанализировать минимум 20 информационный поиск (retrieval)-ошибок и классифицировать причины.

11. Для фиксированных 200 запросов тестовой выборки (test) получить ответы большая языковая модель (LLM) для систем A-D, сохранив инструкция для модели (prompt), извлечённый контекст (retrieved context) и полный ответ.

12. Оценить правильность ответа (answer correctness), релевантность контекста (context relevance), верность источнику (faithfulness), правильность ссылки/идентификатора документа (citation/document-id correctness) и качество отказа от ответа при недостатке данных (abstention quality).

13. Вручную проверить минимум 100 запросов; часть оценок сопоставить с автоматическим большая языковая модель в роли автоматического оценщика (большая языковая модель (LLM)-as-a-judge) и исследовать согласованность оценивания.

14. Построить зависимость качества конечного ответа большая языковая модель (LLM) от полнота в первых k результатах (Recall@k)/средний обратный ранг (MRR) и установить, где улучшение информационный поиск (retrieval) перестает давать заметный прирост генерации.

15. Отдельно исследовать случаи, когда модель повторного ранжирования (reranker) ухудшает результат.

16. Сравнить задержка (latency), число токенов, размер индекса и вычислительную стоимость систем A-D.

17. Исследовать качество по шести подразделениям и определить устойчивость к сдвиг предметной области (domain shift).

18. Сформулировать не менее 5 исследовательских выводов о том, когда трансформерный поиск (трансформер (Transformer) информационный поиск (retrieval))/повторное ранжирование (reranking) оправдан для корпоративной большая языковая модель (LLM)-системы.

4. Что должно быть в итоговой таблице

Система	полнота в первых 5 результатах (Recall@5)	средний обратный ранг (MRR)	нормированная дисконтированная накопленная полезность (nDCG)	Faithfulness	правильность ответа (Answer correctness)	точность ссылок (Citation accuracy)	Latency
Baseline	-	-	-	-	-	-	-
трансформер (Transformer)	-	-	-	-	-	-	-
трансформер (Transformer) + большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))	-	-	-	-	-	-	-

5. Критерии оценивания работы

Критерий	Макс. балл
Организация, роли и воспроизводимость	6
разведочный анализ данных (EDA) и корректность benchmark	9

Лексический базовое решение (baseline)	7
Обучение трансформерный поиск (трансформер (Transformer) информационный поиск (retrieval))	18
Reranking/hybrid и архитектура	14
Ablation и статистика	14
большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG)) evaluation	16
Анализ ошибок и выводы	8
Отчет	4
Защита	4

Максимальный балл: 100.

Разъяснение к оцениванию: оценивается качество исследовательской постановки, корректность сравнения на одном тестовая выборка (test set), доказательность улучшения трансформер-компонент (трансформер (Transformer) component)а, качество интеграции с большая языковая модель (LLM), воспроизводимость и глубина анализа. Высокая метрика сама по себе не компенсирует утечка данных (data leakage), отсутствие базовое решение (baseline), некорректный эксперимент или неподтвержденные выводы.

Итоговый балл	Пояснение
90-100	Исследование выполнено полно; улучшение доказано, абляционное исследование (ablation) и статистическая проверка корректны, большая языковая модель (LLM)-компонент проверяем и обоснован.
80-89	Сильная работа с небольшими недостатками в экспериментальном дизайне или анализе.
70-79	Основная система реализована, но исследовательская часть или доказательство прироста недостаточно глубоки.
60-69	Есть рабочие модели и сравнение, но абляционное исследование (ablation)/statistics/большая языковая модель (LLM) evaluation выполнены частично.
50-59	Решение фрагментарно; трансформер (Transformer)/большая языковая модель (LLM) используются, но улучшение не доказано убедительно.
0-49	Не выполнены ключевые требования, отсутствует корректный базовое решение (baseline)/test comparison или исследовательская работа.

КЕЙС 3. БИЗНЕС: МУЛЬТИМОДАЛЬНЫЙ ПРОГНОЗ СПРОСА И большая языковая модель (LLM)-АНАЛИТИК С ПРОВЕРЯЕМЫМИ УПРАВЛЕНЧЕСКИМИ ОБЪЯСНЕНИЯМИ

1. Постановка задачи

Компания хочет не только прогнозировать спрос, но и получать от большая языковая модель (LLM) объяснение прогноза и рекомендации по запасам. Требуется исследовать, дает ли трансформер (Transformer) реальный прирост относительно классической модели временных рядов/табличного ML и повышает ли текстовый контекст полезность решения. большая языковая модель (LLM) не должен самостоятельно придумывать прогноз: он объясняет результаты моделей и доступные данные.

2. ДАНО

2.1. Обучающая база. Файл «Кейс_3_сложный_спрос_большая языковая модель (LLM)_12000.csv», 12 000 товаров. Поля: категория (category), price_rub, rating, активность промоакции (promo_active), review_sentiment, коэффициент тренда (trend_coef), sales_last_12_periods, текстовый контекст (text_context), продажи в следующем периоде (sales_next_period), класс спроса (demand_class).

2.2. Исследуемые системы. A - классический базовое решение (baseline) по табличным и лаговым признакам (lag features); B - временной трансформер (temporal трансформер (Transformer)); C - векторные представления трансформера (трансформер (Transformer) embeddings) текстового контекста + temporal/объединение табличных признаков (tabular объединение признаков/моделей (fusion)); D - C + информационный поиск (retrieval) похожих исторических товаров + большая языковая модель (LLM)-аналитик.

2.3. Исследовательские гипотезы. H1: временной трансформер (temporal трансформер (Transformer)) улучшает прогноз не для всех категорий. H2: текстовые признаки трансформера (трансформер (Transformer)

features) особенно полезны при промо и изменении тренда. H3: информационный поиск (retrieval) аналогов делает большая языковая модель (LLM)-объяснения конкретнее и снижает число неподтвержденных рекомендаций. H4: лучший прогноз не всегда дает лучшее управленческое объяснение.

2.4. Выход большая языковая модель (LLM). Прогноз спроса; класс спроса; ключевые факторы; 2-3 сопоставимых исторических примера; рекомендация по запасу; риски; явное разделение фактов, модельного прогноза и интерпретации.

3. ТРЕБУЕТСЯ НАЙТИ (ОПРЕДЕЛИТЬ)

1. Провести разведочный анализ данных (EDA) числовых, категориальных, текстовых и временных признаков; проверить выбросы, пропуски и распределения.

2. Построить корректное разбиение и объяснить, почему оно не создает утечка данных (data leakage) между признаками истории и целевым периодом.

3. Реализовать базовое решение (baseline): naive/seasonal naive и классический ML по лаговым/табличным признакам (lag/tabular features).

4. Обучить временной трансформер (temporal трансформер (Transformer)) или трансформер временных рядов (time-series трансформер (Transformer)) и сравнить средняя абсолютная ошибка (MAE), среднеквадратичная ошибка (RMSE), симметричная средняя абсолютная процентная ошибка (sMAPE) с базовое решение (baseline).

5. Получить векторные представления трансформера (трансформер (Transformer) embeddings) текстовый контекст (text_context) и построить мультимодальную объединение признаков/моделей (fusion)-модель.

6. Для класс спроса (demand_class) сравнить макроусреднённая F1-мера (F1)-мера (macro-F1-мера (F1)) и per-class полнота (recall); для продажи в следующем периоде (sales_next_period) - средняя абсолютная ошибка (MAE)/среднеквадратичная ошибка (RMSE)/симметричная средняя абсолютная процентная ошибка (sMAPE).

7. Провести абляционное исследование (ablation): без текста, без временного ряда, без promo/rating, без трансформер (Transformer), без информационный поиск (retrieval).

8. Построить кривые обучения (learning curves) и исследовать зависимость выигрыша трансформер (Transformer) от объема обучающих данных.

9. Оценить статистическую значимость/устойчивость разницы моделей минимум на 5 повторениях или бутстрэп-метод (bootstrap).

10. Исследовать минимум 20 крупных ошибок прогноза и 15 ошибок класс спроса (demand_class).

11. Провести анализ по категория (category), активность промоакции (promo_active) и уровням коэффициент тренда (trend_coef); установить сегменты, где трансформер (Transformer) полезен/бесполезен.

12. Построить информационный поиск (retrieval) похожих исторических товаров/траекторий и измерить качество выбора аналогов по заранее заданной процедуре.

13. Для 200 товаров тестовой выборки (test) сформировать большая языковая модель (LLM)-объяснения в режимах без информационный поиск (retrieval) и с информационный поиск (retrieval).

14. Автоматически проверить, что большая языковая модель (LLM) не изменяет прогноз, цену, рейтинг и другие переданные числовые факты.

15. Вручную оценить минимум 100 пар объяснений по фактическая согласованность (factual consistency), полезность (usefulness), опора на предоставленные данные/источники (grounding) и отсутствию вымышленных причин.

16. Исследовать связь между ошибкой числового прогноза и качеством объяснения большая языковая модель (LLM).

17. Провести стресс-тест: скрыть часть признаков, изменить активность промоакции (promo_active) или добавить шум к тексту и оценить устойчивость системы.

18. Сравнить задержка (latency)/стоимость систем A-D и определить, при каком приросте качества трансформер (Transformer)/большая языковая модель (LLM) экономически оправдан.

19. Подготовить ровно 5 управленческих рекомендаций, каждая должна ссылаться на измеренный результат эксперимента.

20. Сформулировать не менее 5 исследовательских выводов, включая отрицательные результаты.

4. Что должно быть в итоговой таблице

Система	средняя абсолютная ошибка (MAE)	среднеквадратичная ошибка (RMSE)	симметричная средняя абсолютная процентная ошибка (sMAPE)	макроусреднённая F1-мера (F1)-мера (macro-F1-мера (F1))	опора ответа большая языковая модель (LLM) на данные (большая языковая модель (LLM) опора на предоставленные данные/источники (grounding))	сохранение исходных фактов (Fact preservation)	Latency
Baseline	-	-	-	-	-	-	-
трансформер (Transformer)	-	-	-	-	-	-	-
трансформер (Transformer) + большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))	-	-	-	-	-	-	-

5. Критерии оценивания работы

Критерий	Макс. балл
Организация, роли и воспроизводимость	6
разведочный анализ данных (EDA) и постановка эксперимента	9
Baseline	8
Temporal трансформер (Transformer)	16
Мультимодальная объединение признаков/моделей (fusion)-архитектура	14
Ablation, статистика, стресс-тест	16
Retrieval + большая языковая модель (LLM)-аналитик	15
Анализ ошибок и выводы	8
Отчет	4
Защита	4

Максимальный балл: 100.

Разъяснение к оцениванию: оценивается качество исследовательской постановки, корректность сравнения на одном тестовая выборка (test set), доказательность улучшения трансформер-компонент (трансформер (Transformer) component)а, качество интеграции с большая языковая модель (LLM), воспроизводимость и глубина анализа. Высокая метрика сама по себе не компенсирует утечка данных (data leakage), отсутствие базовое решение (baseline), некорректный эксперимент или неподтвержденные выводы.

Итоговый балл	Пояснение
90-100	Исследование выполнено полно; улучшение доказано, абляционное исследование (ablation) и статистическая проверка корректны, большая языковая модель (LLM)-компонент проверяем и обоснован.
80-89	Сильная работа с небольшими недостатками в экспериментальном дизайне или анализе.
70-79	Основная система реализована, но исследовательская часть или доказательство прироста недостаточно глубоки.
60-69	Есть рабочие модели и сравнение, но абляционное исследование (ablation)/statistics/большая языковая модель (LLM) evaluation выполнены частично.

50-59	Решение фрагментарно; трансформер (Transformer)/большая языковая модель (LLM) используются, но улучшение не доказано убедительно.
0-49	Не выполнены ключевые требования, отсутствует корректный базовое решение (baseline)/test comparison или исследовательская работа.

ОБЩИЕ ТРЕБОВАНИЯ К СДАЧЕ

Что должно находиться в интерактивная тетрадь (Notebook)

1. Состав команды, роли и персональный вклад каждого участника.

2. Версии язык Python (Python), библиотек, точные идентификаторы моделей (model IDs) и ссылки на карточки моделей (model cards).

3. Загрузка исходной базы и проверка схемы данных.

4. Полный разведочный анализ данных (EDA) и код визуализаций.

5. Код формирования обучающая/валидационная/тестовая выборки (train/валидация (validation)/test) и начальное значение генератора случайных чисел (seed).

6. Baseline с сохраненными исходные предсказания (raw predictions).

7. трансформер-модель (трансформер (Transformer) model): архитектура, гиперпараметры, оптимизатор (optimizer), планировщик скорости обучения (scheduler), число эпох, ранняя остановка (early stopping).

8. Графики обучения и результаты валидация (validation).

9. Raw predictions всех сравниваемых моделей на одном тестовая выборка (test set).

10. Код абляционное исследование (абляционное исследование (ablation) study) и статистической проверки.

11. Полные инструкции для модели (инструкция для модели (prompt)s) для большая языковая модель (LLM) и параметры генерации.

12. Retrieved context для генерация с дополнением поиском (RAG)/информационный поиск (retrieval) экспериментов.

13. Необработанные ответы большая языковая модель (LLM) для проверяемой выборки.

14. Автоматические и ручные метрики большая языковая модель (LLM).

15. Таблицы сравнений, confidence intervals и визуализации.

16. Список идентификаторов разобранных ошибок.

17. Отдельный раздел отрицательных результатов.

18. Финальные исследовательские выводы.

19. Файлы отчета и презентации.

ОТЧЕТ О ПРОДЕЛАННОЙ РАБОТЕ

Рекомендуемый объем: 15-25 страниц без приложений. Отчет должен позволять восстановить логику исследования и воспроизвести ключевые эксперименты.

1. Титульный лист и состав команды.

2. Постановка задачи и практическая мотивация.

3. Исследовательские вопросы и гипотезы.

4. Описание данных и разведочный анализ данных (EDA).

5. Методика разбиения и защита от утечка данных (data leakage).

6. Baseline.

7. Архитектура трансформер (Transformer) и обоснование решений.

8. Архитектура большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))-компонента.

9. План экспериментов.

10. Основные метрики и статистическая проверка.

11. Ablation study.

12. Анализ ошибок и подгрупп.

13. Оценивание большая языковая модель (LLM) и проверка галлюцинации модели (hallucination)/опора на предоставленные данные/источники (grounding).

14. Вычислительная стоимость и ограничения.

15. Отрицательные результаты.

16. Итоговые выводы.

17. Литература.

ЗАЩИТА РАБОТЫ: ДОКЛАД И ПРЕЗЕНТАЦИЯ

Продолжительность доклада: 12-15 минут, затем вопросы. Рекомендуемый объем презентации: 10-14 слайдов. Каждый участник должен быть готов объяснить свою часть.

1. Задача и практический контекст.

2. Гипотезы.

3. Данные.

4. Baseline.

5. трансформер-архитектура (трансформер (Transformer) architecture).

6. большая языковая модель/генерация с дополнением поиском (большая языковая модель (LLM)/генерация с дополнением поиском (RAG))-архитектура.

7. Экспериментальный дизайн.

8. Основные результаты.

9. Ablation/statistics.

10. Ошибки и отрицательные результаты.

11. Стоимость/задержка (latency).

12. Выводы и ограничения.

На защите архитектор сети объясняет архитектурные решения и абляционное исследование (ablation); аналитик данных - split, утечка данных (data leakage), метрики и статистику; исследователь - гипотезы и интерпретацию; программист - реализацию и воспроизводимость; лидер - интеграцию проекта и итоговые выводы.

Литература 2024-2026 гг.

1. Tire K., Taga E. O., Ildiz M. E., Oymak S. Retrieval Augmented Time Series Forecasting. AISTATS 2026, PMLR 300, pp. 4294-4302.

2. Chakraborty S., Delibasoglu I., Heintz F. Scaling transformers for time series forecasting: do pretrained large models outperform small-scale alternatives? Artificial Intelligence Review, 2026, 59:62.

3. Zhao J., Chu F., Xie L. et al. A survey of transformer networks for time series forecasting. Computer Science Review, 2025. DOI: 10.1016/j.cosrev.2025.100883.

4. Su L., Zuo X., Li R. et al. A systematic review for transformer-based long-term series forecasting. Artificial Intelligence Review, 2025, 58:80.

5. Yang S., Wang D., Zheng H., Jin R. TimeRAG: Boosting LLM Time Series Forecasting via Retrieval-Augmented Generation. ICASSP 2025. DOI: 10.1109/ICASSP49660.2025.10889933.

6. Chen Y., Liu C. A sample-efficient transfer learning framework for industrial remaining useful life prediction leveraging large language models. Reliability Engineering & System Safety, 2026, 268:111980.

7. Gan A., Yu H., Zhang K. et al. Retrieval Augmented Generation Evaluation in the Era of Large Language Models: A Comprehensive Survey. arXiv:2504.14891, 2025.

8. Abdallah A., Piryani B., Mozafari J. et al. How Good are LLM-based Rerankers? An Empirical Analysis of State-of-the-Art Reranking Models. Findings of EMNLP 2025, pp. 5693-5709. DOI: 10.18653/v1/2025.findings-emnlp.305.

9. Han Z., Gao C., Liu J., Zhang J., Zhang S. Q. Parameter-Efficient Fine-Tuning for Large Models: A Comprehensive Survey. arXiv:2403.14608, 2024.

10. Hayou S., Ghosh N., Yu B. LoRA+: Efficient Low Rank Adaptation of Large Models. arXiv:2402.12354, 2024.

11. Yu H., Gan A., Zhang K. et al. Evaluation of Retrieval-Augmented Generation: A Survey. arXiv:2405.07437, 2024.

12. Es S., James J., Espinosa Anke L., Schockaert S. RAGAs: Automated Evaluation of Retrieval Augmented Generation. EACL 2024 System Demonstrations, pp. 150-158.

13. Saad-Falcon J., Khattab O., Potts C., Zaharia M. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. NAACL 2024, pp. 338-354.

14. Rau D., Déjean H., Chirkova N. et al. BERGEN: A Benchmarking Library for Retrieval-Augmented Generation. Findings of EMNLP 2024.

15. Li Z., Li C., Zhang M., Mei Q., Bendersky M. Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach. EMNLP 2024 Industry Track.

16. Ovadia O., Brief M., Mishaeli M., Elisha O. Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs. EMNLP 2024.

17. Huang L., Yu W., Ma W. et al. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. ACM TOIS, 2025, 43(2), Article 42.

18. Mino Calero A., Rasheed A., Lekkas A. M. ChronoSHAP: Revealing temporal patterns from transformers and LTSF-linear models in time series forecasting. Knowledge-Based Systems, 2026, 331:114802.